

Détection Automatisée de Défauts de Surface Sur des Pièces

Objectif : construire un système capable de classier automatiquement des défauts de surface sur des pièces en acier

KODJO Messanh Yaovi

Deep Learning appliqué en entreprise

Plan de la présentation

01

Problématique industrielle

Limites de l'inspection humaine et coût des défauts

02

Dataset

6 types de défauts / 1 800 images 200×200 px

03

Approche méthodologique

Deux architectures comparées sur les mêmes données

04

Entraînement & courbes

Protocole, early stopping, courbes d'apprentissage

05

Résultats & comparaison

F1 par classe, matrice de confusion, prédictions

06

Analyse ROI & conclusion

Impact économique estimé et perspectives

Problématique industrielle

Contexte

- Défauts de surface → rebuts coûteux et retours clients.
- Inspection humaine : variable, fatigable, environ 72 % de précision.
- Cadence industrielle : plusieurs centaines de pièces par heure.
- Besoin : système rapide, répétable, disponible 24 h/24.

→ L'enjeu : dépasser les 72 % et tenir la cadence.

Hypothèses de calcul

150 € coût d'un défaut non détecté

480 000 pièces produites par an

5 % taux de défaut estimé

72 % précision de l'inspecteur humain

38 000 € coût annuel d'un inspecteur

Le dataset

Dataset | 1 800 images | 6 classes | 200×200 px

Craquelures

crazing

Réseau de fines fissures en surface

300 images

Inclusions

inclusion

Particules étrangères dans le métal

300 images

Taches

patches

Zones de coloration irrégulière

300 images

Piqûres

pitted_surface

Petits cratères en surface

300 images

Calamine

rolled-in_scale

Résidus d'oxyde laminés

300 images

Rayures

scratches

Traces linéaires superficielles

300 images

Approche méthodologique

Deux architectures entraînées et comparées sur les mêmes données

CNN from Scratch

Conv2D(32) + BN + ReLU + MaxPool + Dropout(0.10)
Conv2D(64) + BN + ReLU + MaxPool + Dropout(0.15)
Conv2D(128) + BN + ReLU + MaxPool + Dropout(0.20)
Conv2D(256) + BN + ReLU + MaxPool + Dropout(0.25)
AdaptiveAvgPool → Flatten
Dense(512) → Dense(6 classes)

Dropout progressif BatchNorm sur chaque bloc entraîné de zéro.

MobileNetV2 Transfer Learning

Phase 1 — Backbone gelé (lr = 1e-3)

Backbone ImageNet (poids gelés — 3.2 M params)
Tête : Dropout → Linear(1280→512) → ReLU → Linear(512→6)

Seule la tête s'entraîne / backbone intact.

Phase 2 — Fine-tuning (après early stopping)

- 5 derniers blocs du backbone dégelés.
- lr backbone = 1e-4 | lr tête = 5e-4
- LR différentiel : préserve les features ImageNet.



Protocole d'entraînement

Images	200 × 200 px normalisation ImageNet dans les deux cas
Batch / Époques	32 20 époques max (early stopping déclenche avant)
Optimiseur	Adam + ReduceLROnPlateau (×0.5 si pas d'amélioration en 3 époques)
Early stopping	patience = 5 min_delta = 1e-4 sur la val loss
Augmentations	HFlip, VFlip, Rotation ±15°, ColorJitter (train uniquement)
Sauvegarde	Meilleurs poids sauvegardés à chaque amélioration de val accuracy

Courbes d'apprentissage : MobileNetV2

Loss et Accuracy sur train et validation | Early stopping visible

Courbes d'apprentissage - Détection de Défauts de Surface (NEU)






La val loss se stabilise dès l'époque 6-8. L'early stopping évite le surapprentissage.

Comparaison CNN Scratch vs MobileNetV2

Val Accuracy, Val Loss et meilleure précision finale

Comparaison des Modèles — CNN Scratch vs Transfer Learning (MobileNetV2)



98.89 %

MobileNetV2

~ 87 %

CNN Scratch

72 %


Humain (ref)

+ 26 %

Gain vs humain

Résultats détaillés : MobileNetV2

Matrice de confusion | 360 images de validation | 6 classes




F1-score par classe

crazing	1.0000
inclusion	0.9661
patches	1.0000
pitted_surface	1.0000
rolled-in_scale	1.0000
scratches	0.9672

Accuracy : 98.89 %

Prédictions visuelles : exemples réels

Images issues du set de validation | vert = correct | rouge = erreur | orange = considérée saine



Lecture des bordures

Vert	Défaut correctement identifié
Rouge	Mauvaise classification
Orange	Confiance < 65 % → considérée saine



Observations

- Les 4 classes "faciles" sont toujours bien classifiées
- Les rares erreurs concernent inclusion / scratches
- La confiance est généralement très élevée (> 90 %)

Analyse ROI : Impact économique estimé

Systeme IA vs inspection humaine (72 %)

Analyse ROI — Système de Détection Automatisée de Défauts
Précision du modèle : 98.9% | Contexte : Ligne de production acier



Résultats estimés

76 000 €

gain net annuel

~ 9 mois


retour sur investissement

> 150 %


ROI sur 3 ans

+ 26 %

gain vs humain



Répartition des gains annuels



Seuil de rentabilité : environ 78 % de précision.
À 98.89 %, le ROI reste positif même en cas de dégradation

Conclusion

Ce qui a été fait

- Pipeline complet bout-en-bout : données → modèle → évaluation → ROI
- CNN Scratch vs MobileNetV2 sur les mêmes données
- MobileNetV2 : 98.89 % soit +26 % vs inspecteur humain.
- 4 erreurs sur 360, sur 2 classes visuellement proches
- ROI positif dès le 9e mois

Pistes d'amélioration

- Détection d'objets pour localiser le défaut
- Données synthétiques via GAN pour augmenter le dataset
- Quantification pour déploiement embarqué (caméra industrielle)
- Module d'incertitude pour les cas ambigus
- Test sur données réelles en production (drift de domaine)

MobileNetV2 sur le dataset : précision industrielle atteinte dès la première approche

Merci de votre attention

Questions ?

MobileNetV2 | Précision : 98.89 %